作业 A · 一页结论

做什么：把白酒行业 12 家上市公司 2026 年半年报（外加贵州茅台 2021–2025 年报，

给作业 B 当同一份知识底座）做成一个能提问、答案带出处的问答知识库。

一、规模与配置（全部对着课件的口径做）

环节	做法	结果
语料	巨潮资讯网（交易所指定披露平台）下载年报/半年报全文	18 份报告、1,662 页、1,870 万字
提取	PyMuPDF 抽正文 + `find_tables()` 按行列还原表格	表格块占 52%（表格里是财务问题一半的答案）
切块	800 字一块、重合 120 字、句末收尾；带公司/章节/页码/块序号	**11,047 块**
向量①	本机 Qwen3-Embedding-0.6B（1024 维，GPU 编码 206 秒）	43 MB
向量②	阿里 text-embedding-v4（1024 维，API）	43 MB，约 4 元
全文	jieba 分词 + BM25 倒排	词表 40,043
回答	DeepSeek deepseek-v4-flash，逐句带角标、缺材料就说「未覆盖」	平均 8 秒/题

二、10 道题的成绩

8/10 题完全正确（全部单公司题），**2 道跨公司全景题答不出**——这不是实现 bug，

正是课件里那句话的现场复现：*碎块拼不出全景*。

错在哪、怎么修，两道全景题都做了对照实验：

做法	喂进去的块	Q9 覆盖公司数	Q10 覆盖公司数
A 一次检索 top6（基线）	6	2/12	2/12
B 一次检索 top60（把 k 调大）	60	3/12	2/12
C 12 家公司各检索一次	24	3/12	4/12

D 离线抽一张跨公司指标表 + top6	6+表	**12/12**	**12/12**

结论：**加宽窗口和逐家检索都救不了全景题，把结构化事实离线预处理好才有用——**

这就是课件里「知识侧装一层」的账。

三、第一版踩的坑（都留在 `outputs/A_评测记录_v1.md` 里）

第一版 Q1（课件演示的原题：茅台上半年直销收入）答成「材料未覆盖」，查下来是检索的问题：

1. 问茅台时 BM25 把洋河、水井坊的块混进来（都含「渠道/收入」）；

2. 问「2026 年上半年」时，2022/2024/2025 年的同类表格也挤进前 6；

3. RRF 融合让「两条路都出现但都很靠后」的块，压过了「只在向量路靠前」的正确块。

三处一起改，Q1 从「未覆盖」变成完整正确：

`公司名硬过滤 + 报告期硬过滤 + BM25 零分候选剔除 + 向量权重 2:1`。

这道题本身就是课件强调的两件事：**公司名是最强的锚、版本/时效要靠元数据字段管。**

四、花的钱与时间

项目	花费
阿里 text-embedding-v4（11,047 块）	≈ 4 元
DeepSeek（抽检问答对、10 题评测、对照实验）	≈ 8 元
AutoDL 4090 vGPU（向量编码 2 次 + 调试）	≈ 3 元

五、一句话

同一份半年报，**切碎了能秒级召回单点事实**（8 道单公司题全对），

但拼不出跨公司的全景（2 道全景题 baseline 只覆盖 2/12 家）；

真要把全景题做对，靠的不是换更强的向量模型，而是**在知识侧先做一次预处理。**