作业 A · 一页结论：答对的题型、出错的题型及其原因

研究内容：把白酒行业 12 家上市公司 2026 年半年报（外加贵州茅台 2021–2025 年报，同时给作业 B 当知识底座），

构建一个可提问、答案带出处的问答知识库。

规模：18 份报告、1,662 页、1,870 万字 → **11,047 个文本块**（表格块占 52%）

→ Qwen3-Embedding-0.6B 与阿里 text-embedding-v4 两套向量 + jieba BM25 倒排

→ 融合取前 6 块交给 DeepSeek 作答，逐句带角标、材料没有就写「未覆盖」。

一、作业要求回答的三个问题：答对的题型、出错的题型及其原因

问题类型	表现	实测成绩	为什么
单点事实：某一家公司的某个具体数字（营收、净利、直销收入、坏账准备…）	✅ **答对**	**8/8 全对**	答案就在一两块里，向量+BM25 能秒级命中；元数据过滤保证不串公司、不串年份
跨公司数字聚合：12 家里谁增速最高/最低、哪些公司归母净利润同比下降	❌ **出错**	基线只覆盖 **2/12 家**	答案不在任何一块里，而在十几块**之间**；窗口只有 6 块，无法容纳 12 家公司
行业级叙述：普遍面临什么挑战、各家怎么应对	⚠️ **部分答对**	提到 5 家（向量）/ 4 家（重排）	需要对全部文档进行通读，碎块检索只能覆盖其中一部分

小结：**答案落在块内 → 检索能解决；答案落在块之间 → 检索无解。**

二、出错的那两题：错误原因与改进尝试

两道跨公司全景题（Q9 哪家公司营业收入同比增速最高/最低、Q10 哪些公司归母净利润同比下降），逐题记录见 `10题逐题记录.md`。

判分口径是「答案里公司名和数值同时出现才算覆盖到这家公司」。

做法	输入的块	Q9 覆盖	Q10 覆盖
一次检索 top-6（基线）	6	2/12	2/12
把窗口开到 top-60	60	3/12	2/12

12 家公司各检索一次再合并	24	3/12	4/12
详细回合并成一个问题再检索	—	2/12	3/12
离线抽一张跨公司指标表 + top-6 原文	6 + 表	**12/12**	**12/12**

实验结论：加宽窗口、逐家检索、改写问题，都无法解决全景题；把结构化事实离线预处理好才有用

——这就是课程讲义中「知识侧装一层」的账。完整实验记录见 `附件/全景题补救实验.md`。

三、延伸（深度二→深度三）：解决两道出错的题目

按课程规定的六步建了知识图谱：选材 600 块 → 抽实体与关系（**12,498 实体 / 21,942 关系**）

→ 合并描述 → **Leiden** 社区聚类（4 层）→ 社区报告（**1,244 份**）→ 向量化入库。五条路线对比：

路线	**Q9**	**Q10**	**Q11 行业挑战+应对**
向量 RAG（top-6 / 重排）	2–3/12	2–3/12	提到 4–5 家
离线指标表	12/12	12/12	只列数字
图谱 · 读社区报告	4/12	7/12	**唯一给出行业级归纳**
图谱 • 顺「公司→指标=数值（期间/口径）」的边取数	**12/12**	**12/12**	12 家（只数字）

此处有一个值得记录的问题：图谱路线**初始版本为 9/12 和 7/12**，经排查是图中缺少指标边

（同一张主要会计数据表，通用抽取抽到了"营业收入"，但未抽到"营业收入同比增减"）。

用固定 schema 定向补边、并完成一次「12 家 × 关键指标」的覆盖度校验后，达到 **12/12（18–27 秒）**。

完整报告见 `延伸_深度三/图谱全景题报告.md`。

四、第一版检索环节出现的问题

第一版把课程讲义演示的原题（茅台上半年直销收入）答成了「材料未覆盖」。经排查，原因有三：

1. 询问茅台时，BM25 将洋河股份、水井坊的文本块一并召回（均含「渠道 / 收入」等词）；

2. 询问「2026 年上半年」时，2022 年、2024 年、2025 年的同类表格也进入前 6；

3. RRF 融合使「两条路径均出现但名次靠后」的块，压过了「仅在向量路靠前」的正确块。

调整为 `公司名硬过滤 + 报告期硬过滤 + 剔除 BM25 零分候选 + 向量权重 2:1` 后恢复正常。

结论：向量相似度只反映语义接近程度，不反映时效与归属；后者必须由元数据字段承担。

出错原文保留在 `附件/第一版出错记录.md`。

五、账

项目	花费
阿里 text-embedding-v4（11,047 块 + 图谱入库）	≈ 6 元
DeepSeek（评测、建图六步、抽检、补救实验）	≈ 25 元
AutoDL GPU 按小时（向量编码 + 调试）	≈ 8 元

建图天生贵：这一块约 2,500 次调用、5M 量级 token——课程讲义自己也说这是「让模型通读全书的价格」。

六、小结

**同一批财报，切碎了能秒级召回单点事实（8/8 全对），但拼不出跨公司的全景（基线 2/12 家）；

要答全景题，靠的不是换更强的向量模型，而是知识侧的预处理——一张指标表，或者一张织好的图。**