作业 A · 一页结论：哪类题答得好、哪类翻车、为什么

做什么：把白酒行业 12 家上市公司 2026 年半年报（外加贵州茅台 2021–2025 年报，同时给作业 B 当知识底座），

做成一个能提问、答案带出处的问答知识库。

规模：18 份报告、1,662 页、1,870 万字 → **11,047 个文本块**（表格块占 52%）

→ Qwen3-Embedding-0.6B 与阿里 text-embedding-v4 两套向量 + jieba BM25 倒排

→ 融合取前 6 块交给 DeepSeek 作答，逐句带角标、材料没有就写「未覆盖」。

一、老师要的三问：答得好 / 翻车 / 为什么

问题类型	答得好不好	实测成绩	为什么
单点事实：某一家公司的某个具体数字（营收、净利、直销收入、坏账准备…）	✅ **好**	**8/8 全对**	答案就在一两块里，向量+BM25 能秒级命中；元数据过滤保证不串公司、不串年份
跨公司数字聚合：12 家里谁增速最高/最低、谁在净利下滑	❌ **翻车**	基线只覆盖 **2/12 家**	答案不在任何一块里，而在十几块**之间**；窗口只有 6 块，装不下 12 家
行业级叙述：普遍面临什么挑战、各家怎么应对	⚠️ **部分**	提到 5 家（向量）/ 4 家（重排）	需要"读全"，碎块检索只看到其中一角

一句话：**答案落在块内 → 检索能解决；答案落在块之间 → 检索无解。**

二、翻车的那两题：错在哪、试了哪些办法

两道跨公司全景题（Q9 谁营收增速最高/最低、Q10 哪些公司净利下滑），逐题记录见 `10题逐题记录.md`。

判分口径是「答案里公司名和数值同时出现才算覆盖到这家公司」。

做法	喂进去的块	Q9 覆盖	Q10 覆盖
一次检索 top-6（基线）	6	2/12	2/12
把窗口开到 top-60	60	3/12	2/12

12 家公司各检索一次再合并	24	3/12	4/12
详细回合并成一个问题再检索	—	2/12	3/12
离线抽一张跨公司指标表 + top-6 原文	6 + 表	**12/12**	**12/12**

试出来的是：加宽窗口、逐家检索、改写问题，都救不了全景题；把结构化事实离线预处理好才有用

——这就是课件里「知识侧装一层」的账。原文实验记录见 `附件/全景题补救实验.md`。

三、延伸（深度二→深度三）：把翻车的两题救回来

按课件的六步建了知识图谱：选材 600 块 → 抽实体与关系（**12,498 实体 / 21,942 关系**）

→ 合并描述 → **Leiden** 社区聚类（4 层）→ 社区报告（**1,244 份**）→ 向量化入库。五条路线对比：

路线	Q9	Q10	Q11 行业挑战+应对
向量 RAG（top-6 / 重排）	2–3/12	2–3/12	提到 4–5 家
离线指标表	12/12	12/12	只列数字
图谱 · 读社区报告	4/12	7/12	**唯一给出行业级归纳**
图谱 • 顺「公司→指标=数值（期间/口径）」的边捞数	**12/12**	**12/12**	12 家（只数字）

这里有个值得记的坑：图谱路线**第一版只有 9/12 和 7/12**，查出是"图里缺边"（同一张主要会计数据表，

通用抽取抽了"营业收入"却没抽"营业收入同比增减"）。用定死的 schema 定向补边、再做一次

「12 家 × 关键指标」的覆盖度校验后，才到 **12/12（18–27 秒）**。

完整报告见 `延伸_深度三/图谱全景题报告.md`。

四、第一版还踩过一个检索的坑

第一版把课件演示的原题（茅台上半年直销收入）答成了「材料未覆盖」，查下来三条：

1. 问茅台时 BM25 把洋河、水井坊的块混进来（都含「渠道/收入」）；

2. 问「2026 年上半年」时，2022/2024/2025 年的同类表格也挤进前 6；

3. RRF 融合让「两条路都出现但都很靠后」的块，压过了「只在向量路靠前」的正确块。

改成 `公司名硬过滤 + 报告期硬过滤 + 剔除 BM25 零分候选 + 向量权重 2:1` 后转正。

教训：向量只懂"像不像"，不懂"哪个才是本期的"——时效和归属必须靠元数据字段管。

翻车原文留在 `附件/第一版翻车记录.md`。

五、账

项目	花费
阿里 text-embedding-v4（11,047 块 + 图谱入库）	≈ 6 元
DeepSeek（评测、建图六步、抽检、补救实验）	≈ 25 元
AutoDL GPU 按小时（向量编码 + 调试）	≈ 8 元

建图天生贵：这一块约 2,500 次调用、5M 量级 token——课件自己也说这是「让模型通读全书的价格」。

六、一句话总结

**同一批财报，切碎了能秒级召回单点事实（8/8 全对），但拼不出跨公司的全景（基线 2/12 家）；

要答全景题，靠的不是换更强的向量模型，而是知识侧的预处理——一张指标表，或者一张织好的图。**