作业 B · 一页结论

研究内容：用贵州茅台 2021–2025 年报 + 2021–2026 半年报（11 份）训练一个"董秘"——

把「投资者问 / 董秘答（带报告名+页码）」写进 2B 小模型的权重，再和「知识库 + 同一个小模型」比。

一、数据与训练（按课程规定的口径执行）

环节	做法	结果				
语料	茅台 11 份财报，同一套抽正文+表格、800/120 切块	5,690 块				
数据构造	由大模型依据原文生成投资者问答，答案须原样引用数字并标注（来源：报告名 第 X 页）	生成 660 组，其中 73 块原文过于零散、主动跳过				
抽检	①机器核对：将答案中的每个数字回原文比对，对不上/缺出处/页码不符就标出来；②人工核查：导出 40 条抽检表逐条检查	440 条里 3 条有问题，删掉 → **404 条干净样本**（364 训练 / 40 验证）				
结构化文本	Qwen 对话模板（`<|im_start|>system / user / assistant<|im_end|>`）整段渲染后输入模型	见 `data/dongmi/sft_train.jsonl`				
微调	**Qwen3.5-2B**（原生多模态）+ 4bit QLoRA，	**可训练参数 10,911,744 / 1,374,217,024**				

	r=16、α=16、dropout=0，7 个投影层	
硬件	AutoDL RTX 4080S 32G	3 轮 5.8 分钟、6 轮 11.0 分钟

可训练参数 10,911,744 与课程讲义录屏中的数字一致——说明 LoRA 配置和课程是同一套。

二、四格对照（+ 两格知识库对照）

评测集是冻结的 160 条：60 条训练过的事实 + 20 条从未训练的事实，各含原问法和换问法。

判分：参考答案里的关键数字（≥3 位、排除年份）全部答到算对，容差 1%。

下表用的是综合表现最好的一组配置（404 条 × 6 轮权重 + 召回后由 DeepSeek 重排后取 4 块）。

配置	训练过·原问法	训练过·换问法	从未训练·原问法	从未训练·换问法
没微调	3/60（5%）	3/60（5%）	0/20（0%）	0/20（0%）
微调过	3/60（5%）	3/60（5%）	0/20（0%）	0/20（0%）
知识库 + 没微调	18/60（30%）	10/60（17%）	8/20（40%）	5/20（25%）
知识库 + 微调过	**19/60（32%）**	**20/60（33%）**	**8/20（40%）**	**7/20（35%）**

同一批回答的「平均数字命中率」更能说明问题：没材料时 8%，给了知识库 53%，

微调后再给知识库 56%；而且同一套检索下，微调过的合计 34% 明显高于未微调的 26%。

二·补 五轮改进实验的结论（完整记录见 `附件/改进实验对比.md`）

调整项	微调后合计	结论
基线（原 top-6）	31%	作为对照
材料标注口径 + prompt 要求先判口径	31%	对**未微调**的基座有 提高 10 个百分点 增益（19%→29%），对微调后的模型无增益
补充 464 条"带材料"训练样本（808 条 × 3 轮）	27%	该方案未达到预期，低于基线 4 个百分点
召回 30 块后由 DeepSeek 选取 4 块	**34%**	五组中表现最好；上下文含答案比例由 100/160 提升至 111/160

将上下文由 6 块增至 12 块	12%	上下文过多导致注意力分散，效果明显下降

在上述实验范围内，2B 模型的可提升空间已基本用尽：即使提供正确材料，完全答对率仍约为一半，

该差距主要来自模型容量，需更换更大基座。

三、三条结论

1. 微调确实学会了"格式与口吻"，但没学会"事实"。

带出处率从 44/60 涨到 60/60、换问法也稳定带出处；可"完全答对"始终是 5%。

需要说明的是，模型在缺少材料时会生成格式完整、但数字不实的内容。以同一道题

（问 2022 年会计政策变更调减多少）为例：

配置	答案
没微调	"调减了 **1,000.00 万元**，调整前所有者权益 **1,000,000.00 万元**"（明显不实）
微调过	"未分配利润调减 **2,419,030.09** 元，所有者权益调减 **29,193,130.00** 元（来源：2022年年度报告第72页）"（**格式全对、数字全错**）
知识库+微调	"未分配利润调减 3,017,532.39 元，所有者权益合计调减 27,157,791.57 元（来源：2022年年度报告 第66页）" ✅

因此，**仅使用微调、不接入知识库时，输出的形式可信度较高，但数字正确性无法保证。**

2. 事实是靠知识库递进来的，不是靠权重背下来的。

同一道题没材料 8%、给材料 53%；从未训练的事实（0%→40% ）也一样，只有提供材料才能作答。

这与课程决策树的结论一致：**获取新事实 + 保持稳定行为 = 微调 + RAG 配合。**

3. 微调的真实价值是"让它更会用材料"。

在同一套检索条件下，微调后的模型数字命中率为 49%–56%、完全答对率为 32%–40%，

高于未微调基座的 37%–53% 与 17%–40%。可以认为，微调使模型更善于依据材料作答——

即按材料中的表格逐项列出并在末尾标注出处，这正是 SFT 的作用所在。

四、与课程讲义实验结果的差异说明

课程讲义中"训练事实 × 原题"由 2% 提升至 100%；本项目为 5%→5%。差异主要来自数据形态：

- 课程讲义使用的 100 条为**冷门短事实**（如"191 号文明"），答案仅几个字，2B 模型可以记住；

- 本项目的答案为**60–160 字的财务口径描述**，其中包含多位金额，且判分要求每个关键数字均正确——任一位数字不符即判为错误。此类长数值答案不适宜依靠 364 条样本、在 2B 模型的权重中记忆。

佐证：训练轮数由 3 轮增至 6 轮时，数字命中率由 8% 升至 13%，但完全答对率仍为 5%。

即**增加训练轮数可使输出更接近训练集，但此类事实量级不适合由 LoRA 承担**，

该结论与课程讲义"小模型容量有限、事实应通过检索提供"一致。

五、账

项目	花费
问答对生成 + 抽检（DeepSeek）	≈ 6 元
AutoDL 4080S vGPU（环境调试 + 2 次训练 + 640 次评测生成）	≈ 8 元
合计	**≈ 14 元**

六、小结

同一批财报，**建库还是微调？答案是都要，但分工不同**：

知识库负责"事实对不对"（43% vs 8%），微调负责"答得像不像董秘、会不会用材料"（43% → 55%）。

只做前者，答案对但不像人；只做后者，像人但全是编的。