作业 B • 一页结论

做什么：用贵州茅台 2021–2025 年报 + 2021–2026 半年报（11 份）训练一个"董秘"——

把「投资者问 / 董秘答（带报告名+页码）」写进 2B 小模型的权重，再和「知识库 + 同一个小模型」比。

一、数据与训练（对着课件的口径做）

环节	做法	结果				
语料	茅台 11 份财报，同一套抽正文+表格、800/120 切块	5,690 块				
造数据	大模型从原文生成投资者问答，答案必须原样引数字并标（来源：报告名 第 X 页）	生成 660 组，其中 73 块原文太碎主动跳过				
抽检	①机器：答案里每个数字回原文核对，对不上/缺出处/页码不符就标出来；②人工：导出 40 条抽检表逐条看	440 条里 3 条有问题，删掉 → **404 条干净样本**（364 训练 / 40 验证）				
结构化文本	Qwen 对话模板（`<|im_start|>system / user / assistant<|im_end|>`）整段渲染后喂给模型	见 `data/dongmi/sft_train.jsonl`				
微调	**Qwen3.5-2B**（原生多模态）+ 4bit QLoRA，	**可训练参数 10,911,744 / 1,374,217,024**				

	r=16、α=16、dropout=0，7 个投影层	
硬件	AutoDL RTX 4080S 32G	3 轮 5.8 分钟、6 轮 11.0 分钟

可训练参数 10,911,744 和课件录屏里那个数字完全一样——说明 LoRA 配置和课程是同一套。

二、四格对照（+ 两格知识库对照）

评测集是冻结的 160 条：60 条训练过的事实 + 20 条从未训练的事实，各含原问法和换问法。

判分：参考答案里的关键数字（≥3 位、排除年份）全部答到算对，容差 1%。

下表用的是**目前最好的一套配置**（404 条 × 6 轮权重 + 召回后让 DeepSeek 重排取 4 块）。

配置	训练过·原问法	训练过·换问法	从未训练·原问法	从未训练·换问法
没微调	3/60（5%）	3/60（5%）	0/20（0%）	0/20（0%）
微调过	3/60（5%）	3/60（5%）	0/20（0%）	0/20（0%）
知识库 + 没微调	18/60（30%）	10/60（17%）	8/20（40%）	5/20（25%）
知识库 + 微调过	**19/60（32%）**	**20/60（33%）**	**8/20（40%）**	**7/20（35%）**

同一批回答的「平均数字命中率」更能说明问题：没材料时 8%，给了知识库 53%，

微调后再给知识库 56%；而且同一套检索下，微调过的合计 34% 明显高于未微调的 26%。

二·补 五轮改进实验的结论（详见 `B_改进实验对比.md`）

改了什么	微调后合计	结论
基线（原 top-6）	31%	—
材料标口径 + prompt 要求先判口径	31%	对**未微调**的基座 +10pp（19%→29%），对微调过的无增益
补 464 条"带材料"训练数据（808 条 × 3 轮）	27%	**方向不成立**，比基线低 4pp
召回 30 块后让 DeepSeek 挑 4 块	**34%**	**目前最好**，上下文含答案比例 100/160 → 111/160
把上下文从 6 块加到 12 块	12%	反面教材：窗口塞太多，注意力被摊薄

底线一句话：**在 2B 这个体量上，能挤出来的都被挤过了**——剩下的差距

（拿到正确材料也只有约一半能答准）是模型容量问题，换更大基座才是下一步。

三、三条结论

1. 微调确实学会了"格式与口吻"，但没学会"事实"。

带出处率从 44/60 涨到 60/60、换问法也稳定带出处；可"完全答对"始终是 5%。

更值得警惕的是**编造变得更像真的**——看这条同一道题（问 2022 年会计政策变更调减多少）：

配置	答案
没微调	"调减了 **1,000.00 万元**，调整前所有者权益 **1,000,000.00 万元**"（一眼假）
微调过	"未分配利润调减 **2,419,030.09** 元，所有者权益调减 **29,193,130.00** 元（来源：2022年年度报告 第72页）"（**格式全对、数字全错**）
知识库 +微调	"未分配利润调减 3,017,532.39 元，所有者权益合计调减 27,157,791.57 元（来源：2022年年度报告 第66页）" ✅

所以"**只有微调没有知识库的董秘是最危险的**"——它把"看起来可信"学到了，把"对不对"留给了运气。

2. 事实是靠知识库递进来的，不是靠权重背下来的。

同一道题没材料 8%、给材料 43%；从未训练的事实（0%→30% ）也一样，只有给了材料才答得出来。

这和第三课决策树的结论一致：**要新事实 + 要稳定行为 = 微调 + RAG 配合。**

3. 微调的真实价值是"让它更会用材料"。

同样是知识库在前面，微调后的模型数字命中率 43% → 55%、完全答对 20% → 37%。

它学会了"照着材料里的表逐项列出来、末尾标出处"，这正是 SFT 该干的事。

四、和课件那次实验的差别（诚实说明）

课件里"训练事实×原题 2%→100%"，我们这里是 5%→5%。原因不在方法而在数据形态：

- 课件那 100 条是**冷门短事实**（如"191 号文明"），答案是几个字，2B 模型背得住；
- 我们的答案是**60–160 字的财务口径描述**，里面一串 12 位金额，且判分要求每个数字都对——

  7 位数字错 1 位就算错。把这种长数值答案塞进 2B 模型、364 条样本，本身就不现实。

一个佐证：训练轮数从 3 轮加到 6 轮，数字命中率 8%→13%（在动），但"完全答对"仍是 5%——

多轮训练能让它更接近训练集，但这类事实量级不是 LoRA 该扛的活。这条和课件"小模型快但容量到顶、

事实要靠检索递进来"是同一个结论。

五、账

项目	花费
问答对生成 + 抽检（DeepSeek）	≈ 6 元
AutoDL 4080S vGPU（环境调试 + 2 次训练 + 640 次评测生成）	≈ 8 元
合计	**≈ 14 元**

六、一句话

同一批财报，**建库还是微调？答案是都要，但分工不同**：

知识库负责"事实对不对"（43% vs 8%），微调负责"答得像不像董秘、会不会用材料"（43% → 55%）。

只做前者，答案对但不像人；只做后者，像人但全是编的。